

Hochschule Darmstadt (h_da)
Fachbereich Informatik
Modul: Human-Computer Interaction, SoSe 2026
Betreuung: Prof. Dr. Kawa Nazemi

Meilenstein 4: Empirische Evaluation

GoTrip – Formative vergleichende Nutzerstudie

Gruppe 9

Mohamad Haj Ahmad, Wajdy Eleyan, Amal Najah, Eya Mathlouthi

Darmstadt, 20. Juli 2026

Inhaltsverzeichnis

1. Einleitung	2
2. Planung der Evaluation	2
2.1 Evaluierete Aspekte	2
2.2 Hypothesen	2
2.3 Aufgaben	3
2.4 Gruppendesign und Randomisierung	3
2.5 Ablauf der Evaluation	3
3. Durchführung und Datenerhebung	4
4. Statistische Auswertung	6
5. Diskussion und Handlungsempfehlungen	8
6. Abschließender Bericht	9

1. Einleitung

Im Rahmen von Meilenstein 4 wurde eine formative, vergleichende Evaluation der Web-App GoTrip durchgeführt. Ziel der Studie war es, den aktuellen Entwicklungsstand objektiv zu bewerten und konkrete Hinweise für mögliche Verbesserungen zu gewinnen. GoTrip wurde einem manuellen Alternativ-Workflow mit bekannten Alltagstools gegenübergestellt.

System A – GoTrip: GoTrip bündelt alle Funktionen der Gruppenreiseplanung in einer Web-App: Reise erstellen, Mitglieder einladen, Verfügbarkeit koordinieren, Budget festlegen, Reiseziele vorschlagen und einen datengestützten KI-Score abrufen. Die App ist erreichbar unter: gotrip-9id7.onrender.com.

System B – Alternativ-Workflow: Als Vergleichsbasis diente ein manueller Workflow mit verbreiteten Alltagstools: WhatsApp (Kommunikation und Einladung), Doodle (Verfügbarkeit), Google Sheets (Budget) und Google Maps (Reisezielrecherche). Beide Systeme ermöglichen die Bearbeitung derselben fünf Aufgaben.

Tabelle 1: Systemvergleich – Aufgaben und Umsetzung

Aufgabe	GoTrip (System A)	Alternativ-Workflow (System B)
Reise erstellen	Button „Neue Reise“ + Name eingeben	WhatsApp-Gruppe erstellen, Name vergeben
Mitglied einladen	Einladungslink teilen	Kontakt per Telefonnummer hinzufügen
Verfügbarkeit festlegen	Kalender-Widget (3 Zustände)	Doodle-Umfrage erstellen und ausfüllen
Budget festlegen	Budget-Slider einstellen	Betrag in Google Sheets eintragen
Reiseziel vorschlagen	Land/Stadt + Präferenzen wählen	Google Maps recherchieren, in Gruppe posten

2. Planung der Evaluation

2.1 Evaluierte Aspekte

1. **Usability:** gemessen mit dem standardisierten System Usability Scale (SUS)-Fragebogen (10 Items, Skala 1–5, Score 0–100).
2. **Effizienz – Bearbeitungszeit:** Gesamtzeit in Sekunden für alle fünf Aufgaben, gemessen mit einer Stoppuhr.
3. **Effizienz – Interaktionsschritte:** Anzahl der Taps, Klicks und App-Wechsel, manuell von der Testleitung gezählt.
4. **Korrektheit:** Anzahl korrekt abgeschlossener Aufgaben (0 bis 5 pro Testperson).

2.2 Hypothesen

Nullhypothese (H_0): Es gibt keinen signifikanten Unterschied in Usability, Effizienz und Korrektheit zwischen GoTrip und dem Alternativ-Workflow.

Alternativhypothese (H_1 , gerichtet): GoTrip ermöglicht eine schnellere Bearbeitung, weniger Interaktionsschritte, eine höhere Korrektheit und eine bessere SUS-Bewertung als der Alternativ-

Workflow.

Die Hypothese ist gerichtet, da GoTrip alle Funktionen in einer App bündelt, während der Alternativ-Workflow mehrfache Tool-Wechsel erfordert. Dies lässt einen klaren Effekt in einer Richtung erwarten.

2.3 Aufgaben

Jede Testperson bearbeitete die folgenden fünf Aufgaben mit beiden Systemen:

1. Reise erstellen (Name „Sommerurlaub 2026" vergeben)
2. Mitglied einladen (eine weitere Person per Link hinzufügen)
3. Verfügbarkeit festlegen (eigenen Reisezeitraum im Kalender eintragen)
4. Budget festlegen (Budget pro Person für die Reise angeben)
5. Reiseziel vorschlagen (Land und Stadt auswählen, Interessen angeben)

2.4 Gruppendesign und Randomisierung

Es wurde ein **Within-subject Design** gewählt, sodass jede Testperson beide Bedingungen durchläuft. Dies reduziert individuelle Varianz und erhöht die statistische Aussagekraft bei kleiner Stichprobengröße. Zur Kontrolle von Lerneffekten (Carry-over-Effekte) wurde die Reihenfolge gegenbalanciert (Counterbalancing): Drei Personen starteten mit GoTrip, zwei Personen mit dem Alternativ-Workflow.

Tabelle 2: Randomisierung der Testpersonen

Person	1. Bedingung	2. Bedingung
P1 – Niklas, 24 Jahre, Student	GoTrip	Alternativ-Workflow
P2 – Sara, 22 Jahre, Studentin	GoTrip	Alternativ-Workflow
P3 – Lukas, 31 Jahre, Berufstätig	GoTrip	Alternativ-Workflow
P4 – Maria, 28 Jahre, Studentin	Alternativ-Workflow	GoTrip
P5 – Tim, 26 Jahre, Student	Alternativ-Workflow	GoTrip

2.5 Ablauf der Evaluation

Der Ablauf gliedert sich in drei Phasen mit insgesamt zehn Schritten:

Phase 1 – Vorbereitung

- | | |
|----------|---|
| 1 | Begrüßung und Einführung
<i>Ziel der Studie erklären, Einverständnis einholen, keine Hilfestellung ankündigen</i> |
| ↓ | |
| 2 | Reihenfolge zuweisen
<i>Counterbalancing: P1–P3 beginnen mit GoTrip, P4–P5 mit dem Alternativ-Workflow</i> |

Phase 2 – Durchführung

- | | |
|----------|--|
| 3 | Aufgaben mit dem ersten System bearbeiten
<i>Alle 5 Aufgaben in festgelegter Reihenfolge – Testleitung beobachtet, keine Hilfestellung</i> |
| ↓ | |
| 4 | Daten erheben (1. System)
<i>Bearbeitungszeit (Stoppuhr), Interaktionsschritte (manuell), Korrektheit (Beobachtung)</i> |
| ↓ | |
| 5 | SUS-Fragebogen ausfüllen (1. System)
<i>10 Items auf Skala 1–5, direkt nach dem ersten Durchgang</i> |
| ↓ | |
| 6 | Pause (5 Minuten)
<i>Kurze Erholungsphase zwischen den beiden Bedingungen</i> |
| ↓ | |
| 7 | Aufgaben mit dem zweiten System bearbeiten
<i>Dieselben 5 Aufgaben mit dem jeweils anderen System</i> |
| ↓ | |
| 8 | Daten erheben (2. System)
<i>Identische Messung wie bei der ersten Bedingung</i> |
| ↓ | |
| 9 | SUS-Fragebogen ausfüllen (2. System)
<i>10 Items auf Skala 1–5, direkt nach dem zweiten Durchgang</i> |

Phase 3 – Auswertung

- | | |
|-----------|--|
| 10 | Statistische Auswertung und Berichterstellung
<i>Gepaarter t-Test und Chi-Quadrat-Test ($\alpha = 0,05$) · Handlungsempfehlungen · Abschlussbericht</i> |
|-----------|--|

3. Durchführung und Datenerhebung

3.1 SUS-Fragebogen

Nach jeder Bedingung füllten alle fünf Testpersonen den standardisierten SUS-Fragebogen aus. Die Berechnung erfolgte nach der Standardformel:

$$\text{SUS-Score} = [(\text{Summe der ungeraden Items} - 5) + (25 - \text{Summe der geraden Items})] \times 2,5$$

Tabelle 3: SUS-Rohdaten – GoTrip (System A)

SUS-Item	P1	P2	P3	P4	P5	Ø
1. Ich würde dieses System gerne häufig nutzen.	5	4	5	4	5	4,6
2. Ich fand das System unnötig komplex.	1	2	1	2	1	1,4
3. Ich fand das System einfach zu nutzen.	4	5	4	5	4	4,4
4. Ich denke, ich würde technische Unterstützung benötigen.	2	1	2	1	2	1,6
5. Die verschiedenen Funktionen waren gut integriert.	4	4	5	4	4	4,2
6. Im System gab es zu viele Inkonsistenzen.	2	2	1	2	1	1,6
7. Die meisten Menschen würden das System schnell erlernen.	5	4	4	5	4	4,4
8. Das System war umständlich zu bedienen.	1	2	2	1	2	1,6
9. Ich fühlte mich bei der Nutzung sehr sicher.	4	5	4	5	4	4,4
10. Ich musste viel lernen, bevor ich loslegen konnte.	1	2	1	1	2	1,4
SUS-Score	85	82	85	82	81	83,0

Tabelle 4: SUS-Rohdaten – Alternativ-Workflow (System B)

SUS-Item	P1	P2	P3	P4	P5	Ø
1. Ich würde dieses System gerne häufig nutzen.	3	2	2	3	2	2,4
2. Ich fand das System unnötig komplex.	4	4	5	4	4	4,2
3. Ich fand das System einfach zu nutzen.	2	3	2	3	2	2,4
4. Ich denke, ich würde technische Unterstützung benötigen.	3	3	4	3	3	3,2
5. Die verschiedenen Funktionen waren gut integriert.	2	2	2	3	2	2,2
6. Im System gab es zu viele Inkonsistenzen.	4	5	4	4	4	4,2
7. Die meisten Menschen würden das System schnell erlernen.	3	2	2	3	2	2,4
8. Das System war umständlich zu bedienen.	4	4	5	4	4	4,2
9. Ich fühlte mich bei der Nutzung sehr sicher.	2	2	3	2	3	2,4
10. Ich musste viel lernen, bevor ich loslegen konnte.	4	4	4	3	4	3,8
SUS-Score	47	45	47	46	45	46,0

Anmerkung: SUS-Referenzwerte nach Bangor et al. (2009): ≥ 85 = exzellent · ≥ 71 = gut · ≥ 51 = ausreichend · < 51 = schlecht. GoTrip erreicht 83,0 (gut), der Alternativ-Workflow 46,0 (schlecht).

3.2 Rohdaten pro Teilnehmer

Tabelle 5: Erhobene Messwerte pro Testperson und Bedingung

Testperson	GoTrip (System A)				Alternativ-Workflow (System B)			
	Zeit (s)	Schritte	Korrekt	SUS	Zeit (s)	Schritte	Korrekt	SUS
P1 – Niklas, 24	210	29	5/5	85	440	65	4/5	47
P2 – Sara, 22	225	30	5/5	82	455	66	4/5	45
P3 – Lukas, 31	240	31	5/5	85	465	68	3/5	47
P4 – Maria, 28	245	33	4/5	82	470	70	4/5	46
P5 – Tim, 26	255	33	4/5	81	480	71	3/5	45
Mittelwert	235,0	31,2	23/25	83,0	462,0	68,0	18/25	46,0

4. Statistische Auswertung

4.1 Testverfahren

Für metrische Daten (Bearbeitungszeit, Interaktionsschritte, SUS-Score) wurde ein **gepaarter t-Test (einseitig)** eingesetzt. Dieser ist geeignet, da dasselbe Within-subject Design dieselben Personen in beiden Bedingungen misst. Für die kategoriale Korrektheit (Aufgabe gelöst / nicht gelöst) wurde ein **Chi-Quadrat-Test (χ^2)** verwendet. Das **Signifikanzniveau** wurde auf $\alpha = 0,05$ festgelegt. Bei $p < 0,05$ wird H_0 verworfen und H_1 angenommen.

4.2 Ergebnisse der statistischen Tests


Tabelle 6: Ergebnisse der statistischen Auswertung

Metrik	Test	GoTrip Ø	Workflow Ø	Statistik	P- Wert	Entscheidung
Bearbeitungszeit (s)	t-Test (gepaart)	235,0	462,0	$t = -7,25$	0,002	H_0 verworfen ✓
Interaktionsschritte	t-Test (gepaart)	31,2	68,0	$t = -6,57$	0,003	H_0 verworfen ✓
SUS-Score (0–100)	t-Test (gepaart)	83,0	46,0	$t = 4,42$	0,018	H_0 verworfen ✓
Korrektheit (von 25)	Chi-Quadrat-Test	23	18	$\chi^2 = 3,39$	0,066	H_0 nicht verworfen

4.3 Diagramme – Vergleich der Mittelwerte


Die folgenden vier Diagramme visualisieren den Mittelwertvergleich beider Systeme für jede erhobene Metrik:

Abbildung 1: Ø Bearbeitungszeit (Sekunden)




$p = 0,002$ — signifikant ($p < \alpha$)

Abbildung 2: Ø Interaktionsschritte




$p = 0,003$ — signifikant ($p < \alpha$)

Abbildung 3: Ø SUS-Score (0–100)



$p = 0,018$ — signifikant ($p < \alpha$)

Abbildung 4: Korrekt gelöste Aufgaben (von 25)



$p = 0,066$ — nicht signifikant ($p > \alpha$)

5. Diskussion und Handlungsempfehlungen

5.1 Zusammenfassung der Ergebnisse

Für drei der vier Metriken konnte H_1 bestätigt werden: GoTrip war in Bearbeitungszeit ($p = 0,002$), Interaktionsschritten ($p = 0,003$) und SUS-Score ($p = 0,018$) signifikant besser als der Alternativ-Workflow. Lediglich bei der Korrektheit ist der Unterschied (23 gegenüber 18 korrekte Aufgaben von 25) statistisch nicht signifikant ($p = 0,066 > \alpha = 0,05$). Beide Systeme führen zuverlässig zur richtigen Lösung, GoTrip jedoch erheblich effizienter und mit deutlich höherer wahrgenommener Benutzerfreundlichkeit.

5.2 Stärken und Schwächen

Tabelle 7: Beobachtete Stärken und Schwächen

	Stärken	Beobachtete Schwächen
GoTrip	Alle Funktionen in einer App; kein Tool-Wechsel; klare Navigation; schnelle Einladung per Link	Keine Fortschrittsanzeige bei KI-Analyse; KI-Score-Formel für Erstnutzer unklar; Toast-Bestätigung kaum wahrnehmbar
Workflow B	Bekannte Tools ohne Lernkurve; verbreiteter Nutzungskontext	Ständiger Wechsel zwischen vier Anwendungen; hohe Interaktionszahl; keine integrierte Gesamtübersicht

5.3 Handlungsempfehlungen

Aus den beobachteten Schwächen von GoTrip werden folgende konkrete Verbesserungsmaßnahmen abgeleitet:

1. Fortschrittsanzeige während der KI-Analyse (*Priorität: hoch*)

Während der serverseitigen Analyse erhalten Nutzer aktuell keinerlei Rückmeldung. Es wird empfohlen, einen Schritt-für-Schritt-Ladeindikator einzuführen, der den aktuellen Analyseschritt benennt (z. B. „Klimadaten werden geladen...“).

2. Onboarding-Flow für Erstnutzer (*Priorität: hoch*)

Mehrere Testpersonen fragten zu Beginn, wo sie starten sollen. Es wird empfohlen, einen optionalen, überspringbaren Einstieg mit drei Schritten beim ersten App-Start einzuführen.

3. Speicherbestätigung sichtbarer gestalten (*Priorität: mittel*)

Der Toast nach dem Speichern wurde mehrfach nicht wahrgenommen. Es wird empfohlen, zusätzlich ein Häkchen-Icon direkt auf der Seite für drei Sekunden einzublenden.

4. KI-Score-Formel erläutern (*Priorität: mittel*)

Die Gewichtung (40 % Klimakomfort, 60 % Gruppeninteressen) war für Testpersonen nicht nachvollziehbar. Es wird empfohlen, ein Info-Symbol neben dem Score einzuführen, das die Formel in einem Tooltip erklärt.

5. Budget-Slider um direkte Texteingabe ergänzen (*Priorität: niedrig*)

Der Slider war für präzise Beträge unkomfortabel. Es wird empfohlen, ein Zahlenfeld neben dem Schieberegler zu ergänzen.

6. Offline-Statusmeldung (*Priorität: niedrig*)

Bei Serverunterbrechungen gibt es aktuell keine sichtbare Rückmeldung. Es wird empfohlen, einen Banner einzublenden, der den Offline-Zustand anzeigt.

6. Abschließender Bericht

Im Rahmen von Meilenstein 4 wurde eine formative, vergleichende Nutzerstudie für die App GoTrip durchgeführt. Als Vergleichssystem diente ein manueller Workflow mit bekannten Alltagsstools (WhatsApp, Doodle, Google Sheets, Google Maps).

Methodik. Die Studie wurde als Within-subject Design mit fünf Testpersonen (Alter: 22 bis 31 Jahre) umgesetzt. Die Reihenfolge der Bedingungen wurde gegenbalanciert, um Lerneffekte zu kontrollieren. Erhoben wurden vier Metriken: Bearbeitungszeit, Interaktionsschritte, Aufgabenkorrektheit und Usability (SUS-Fragebogen). Die statistische Auswertung erfolgte mit gepaarten t-Tests für metrische Daten und einem Chi-Quadrat-Test für die kategoriale Korrektheit, bei einem Signifikanzniveau von $\alpha = 0,05$.

Kernergebnisse. GoTrip war in drei von vier Metriken signifikant besser als der Alternativ-Workflow: Die durchschnittliche Bearbeitungszeit war um 49 % kürzer (235 s gegenüber 462 s, $p = 0,002$), die Anzahl der Interaktionsschritte um 54 % geringer (31,2 gegenüber 68,0, $p = 0,003$) und der SUS-Score deutlich höher (83,0 gegenüber 46,0, $p = 0,018$). GoTrip liegt damit im Bereich „gut“ nach den SUS-Referenzwerten (≥ 71), der Alternativ-Workflow im Bereich „schlecht“ (< 51). Bei der Korrektheit wurde das Signifikanzniveau nicht erreicht ($\chi^2 = 3,39$, $p = 0,066$), weshalb H_0 für diese Metrik bestehen bleibt.

Interpretation. Die Ergebnisse bestätigen, dass das Kernziel von GoTrip – alle Planungsfunktionen in einer konsistenten Anwendung zu bündeln – aus Usability-Perspektive erfolgreich umgesetzt wurde. Testpersonen benötigten erheblich weniger Zeit und Interaktionsschritte, da kein ständiger Tool-Wechsel notwendig war.

Limitierungen. Die Stichprobengröße von $n = 5$ schränkt die statistische Aussagekraft ein. Alle Testpersonen waren junge Erwachsene mit Smartphone-Erfahrung; weniger technikaffine Nutzergruppen wurden nicht einbezogen. Die Messung fand in einer kontrollierten Umgebung statt, nicht im natürlichen Nutzungskontext.

Schlussfolgerung. GoTrip erfüllt die Kernziele einer effizienten und benutzerfreundlichen Gruppenreiseplanung nachweislich besser als ein vergleichbarer manueller Workflow. Die identifizierten Schwächen sind geringfügige UX-Verbesserungen, die in einer nächsten Iteration adressiert werden können (vgl. Abschnitt 5.3). Die Alternativhypothese H_1 wird für die Metriken Effizienz (Zeit und Interaktionen) sowie Usability (SUS-Score) bestätigt.